Сравнительный анализ методов нормализации и архитектур прогнозирования временных рядов на данных M4

Леусенко Артем Валерьевич
Шаповалов Владислав Эдуардович
Гельдаш Алина Владимировна
Национальный исследовательский университет «Высшая школа экономики»
Факультет компьютерных наук,
Департамент анализа данных и искусственного интеллекта
Проектная работа по курсу «Анализ временных рядов», 2026

14 марта 2026 г.

Аннотация

Настоящая работа посвящена исследованию влияния методов нормализации на качество прогнозирования временных рядов при использовании моделей различных классов. В условиях растущей популярности глобальных подходов к прогнозированию, предполагающих обучение единой модели на множестве рядов, вопрос корректной предобработки данных приобретает особую значимость. В рамках исследования проводится сравнительный анализ четырех методов масштабирования (StandardScaler, RobustScaler, QuantileTransformer) при их применении к шести моделям: наивные бейзлайны, автоматизированные статистические методы, градиентный бустинг CatBoost и нейросетевая архитектура PatchTST. Эксперименты выполняются на подвыборке из 50 временных рядов часового разрешения из датасета M4. Полученные результаты демонстрируют критическую зависимость нейросетевых архитектур от нормализации: применение StandardScaler позволило улучшить качество PatchTST на 41.4% (снижение SMAPE с 45.2% до 26.5%). Оптимизированная версия PatchTST превосходит CatBoost на 7.2 процентных пункта по среднему SMAPE, достигая на отдельных рядах значения 18.8%. Выявлено, что простая сезонная наивная модель остается сильнейшим конкурентом на коротких горизонтах прогнозирования (SMAPE 12-15%), что свидетельствует о доминировании сезонной компоненты в данных часового разрешения.

1 Введение

Прогнозирование временных рядов представляет собой одну из фундаментальных задач анализа данных, находящую применение в широком спектре предметных областей — от макроэкономического планирования до оперативного управления энергосистемами. Традиционный подход к решению данной задачи предполагает построение индивидуальной модели для каждого временного ряда, что позволяет учитывать его уникальные статистические характеристики. Однако в последние годы наблюдается устойчивый тренд в сторону использования так называемых глобальных моделей, обучаемых одновременно на множестве рядов и способных извлекать общие паттерны, инвариантные относительно конкретной реализации процесса.

Переход к глобальному обучению порождает ряд методологических проблем, среди которых особое место занимает вопрос нормализации данных. Разномасштабность рядов, обусловленная различиями в единицах измерения, амплитудах колебаний и уровнях волатильности, делает невозможным непосредственное совместное обучение без предварительного приведения к сопоставимому виду. При этом выбор конкретного метода нормализации может оказывать существенное влияние на итоговое качество прогнозов, причем характер этого влияния, предположительно, различается для моделей разных классов.

Целью настоящей работы является эмпирическая проверка гипотезы о том, что чувствительность к нормализации коррелирует со сложностью модели и ее архитектурными особенностями. В рамках исследования решаются следующие задачи: реализация экспериментального пайплайна, включающего четыре метода масштабирования; сравнительный анализ шести моделей, относящихся к трем различным классам; оптимизация гиперпараметров нейросетевой архитектуры PatchTST; количественная оценка влияния нормализации на итоговое качество прогнозов.

2 Постановка задачи и гипотеза исследования

Рассматривается задача прогнозирования временных рядов в постановке с фиксированным горизонтом. Для каждого временного ряда $\{y_t\}_{t=1}^{T}$ требуется построить прогноз $\{\hat{y}_t\}_{t=T+1}^{T+H}$ на H шагов вперед. Качество прогноза оценивается с использованием симметричной средней абсолютной процентной ошибки:

$$\text{SMAPE} = \frac{100\%}{H} \sum_{i=1}^{H} \frac{|y_{T+i} - \hat{y}_{T+i}|}{(|y_{T+i}| + |\hat{y}_{T+i}|)/2} \tag{1}$$

Выбор данной метрики обусловлен ее широким распространением в конкурсах по прогнозированию, в частности в M4, а также устойчивостью к нулевым значениям и симметричностью относительно знака ошибки.

Гипотеза исследования формулируется следующим образом: нормализация данных оказывает неоднородное влияние на модели различных классов, причем степень этого влияния возрастает с увеличением сложности модели и ее зависимости от межрядовой информации. Ожидается, что:

1. Нейросетевые архитектуры, обучаемые на признаках, будут демонстрировать критическую зависимость от выбора метода нормализации, причем оптимальный метод может различаться в зависимости от статистических характеристик данных;

2. Модели градиентного бустинга, обладающие inherent устойчивостью к монотонным преобразованиям, будут в меньшей степени подвержены влиянию нормализации, однако также могут выигрывать от приведения данных к сопоставимому масштабу;

3. Простые статистические модели, не использующие межрядовую информацию, будут инвариантны к масштабированию, поскольку оперируют исключительно значениями конкретного ряда;

4. При достаточной оптимизации гиперпараметров нейросетевые архитектуры способны превзойти градиентный бустинг, несмотря на более высокие требования к объему данных и вычислительным ресурсам.

3 Распределение ролей в команде

Проект выполнялся: Леусенко А.В. разработал модуль загрузки и предобработки данных, включая интеграцию с API датасета M4 и реализацию статистических бейзлайнов на базе библиотеки statsmodels. Гельдаш А.В. реализовала циклы обучения глобальных моделей: выполнена адаптация архитектуры PatchTST под PyTorch, а также настроен градиентный бустинг CatBoost с формированием лаговых признаков. Шаповалов В.Э. отвечал за инфраструктурную часть: реализовал конвейеры нормализации с использованием инструментов scikit-learn, разработал систему логирования экспериментов и подготовил визуализации для анализа результатов. Совместная работа велась с использованием системы контроля версий Git.

4 Описание данных

Эмпирической базой исследования служит датасет M4, разработанный для проведения открытого соревнования по прогнозированию временных рядов и ставший де-факто стандартом для бенчмаркинга новых методов. Выбор данного датасета обусловлен его репрезентативностью, наличием размеченных обучающих и тестовых выборок, а также широким спектром временных рядов различной природы и частоты дискретизации.

Для проведения экспериментов использована подвыборка из 50 временных рядов **часового разрешения** (Hourly). Выбор именно часовой частоты продиктован следующими соображениями:

- Наличие выраженной сезонности с периодами 24 часа (суточный цикл) и 168 часов (недельный цикл), что позволяет оценить способность моделей улавливать множественные сезонные структуры;

- Достаточная длина рядов (в среднем 700-800 наблюдений) для обучения как локальных, так и глобальных моделей;

- Разнообразие масштабов рядов: значения варьируются от единиц до десятков тысяч, что создает естественные предпосылки для изучения влияния нормализации.

Горизонт прогнозирования для всех рядов составляет $H = 48$ шагов, что соответствует двум полным суточным циклам. Такая длина горизонта позволяет оценить как краткосрочную точность прогнозов (первые 6-12 часов), так и способность моделей сохранять качество на среднесрочной перспективе (24-48 часов).

Разделение на обучающую и тестовую выборки осуществляется в соответствии с оригинальной разметкой датасета M4, что обеспечивает сопоставимость результатов с опубликованными бенчмарками. Дополнительно, для нейросетевой модели выделяется валидационная выборка, формируемая путем случайного отбора 20% рядов (10 рядов) для мониторинга переобучения и ранней остановки обучения.

5 Методология экспериментального исследования

5.1 Дизайн эксперимента

Для проверки сформулированной гипотезы реализован полный факторный эксперимент, в рамках которого каждая из рассматриваемых моделей тестируется при четырех различных режимах нормализации. Такой дизайн позволяет выделить чистое влияние метода масштабирования, исключая вариативность, связанную с другими факторами.

Общая схема эксперимента для каждой комбинации «модель–метод нормализации» включает следующие этапы:

1. Для каждого временного ряда вычисляются параметры масштабирования на обучающей выборке;
2. Обучающие данные всех рядов преобразуются с использованием вычисленных параметров;
3. Производится обучение модели (индивидуально для каждого ряда в случае локальных моделей или на объединенных данных в случае глобальных);
4. Строятся прогнозы на тестовой выборке, которые затем обратно преобразуются в исходную шкалу с использованием сохраненных параметров масштабирования;
5. Рассчитываются метрики качества путем сопоставления прогнозов с фактическими значениями.

Фиксация случайного зерна на всех этапах эксперимента обеспечивает детерминированность результатов и их воспроизводимость при повторных запусках.

5.2 Методы нормализации

В работе сравниваются четыре подхода к масштабированию данных, реализованные в библиотеке scikit-learn:

1. **Отсутствие нормализации (No scaling)**. Данные подаются в модель в исходном виде. Данный режим служит базой для сравнения и позволяет количественно оценить эффект от применения нормализации.
2. **Стандартизация (StandardScaler)**. Преобразование, приводящее данные к нулевому среднему и единичной дисперсии:
$$x_{\text{scaled}} = \frac{x - \mu}{\sigma} \tag{2}$$
где μ — среднее арифметическое, σ — стандартное отклонение. Данный метод чувствителен к наличию выбросов, которые могут существенно искажать оценки μ и σ.
3. **Робастное масштабирование (RobustScaler)**. Использование медианы и межквартильного размаха вместо среднего и стандартного отклонения:
$$x_{\text{scaled}} = \frac{x - \text{median}(x)}{\text{IQR}(x)} \tag{3}$$
где $\text{IQR}(x) = Q_3(x) - Q_1(x)$. Данный подход обеспечивает устойчивость к выбросам, что может быть критично для рядов с редкими, но значительными аномалиями.

4. **Квантильное преобразование (QuantileTransformer)**. Нелинейное преобразование, приводящее распределение данных к заданному (равномерному или нормальному). Метод основан на оценке эмпирической функции распределения и последующем отображении квантилей. Особенно эффективен для данных с тяжелыми хвостами или мультимодальным распределением.

Важно подчеркнуть, что все преобразования применяются индивидуально к каждому ряду, а параметры масштабирования вычисляются исключительно по обучающей выборке во избежание утечки данных.

6 Анализируемые модели

В рамках исследования рассмотрены три принципиально различных класса моделей прогнозирования, что позволяет оценить взаимодействие «архитектура–нормализация» в широком спектре подходов.

6.1 Локальные статистические модели

Первый класс образуют модели, обучаемые индивидуально на каждом временном ряду. Данные модели служат бейзлайнами и позволяют оценить минимально достижимый уровень качества при отсутствии межрядового обобщения.

Наивная модель (Naive). Простейший метод прогнозирования, при котором прогноз на все горизонты повторяет последнее наблюдение обучающей выборки:

$$\hat{y}_{T+h} = y_T, \quad h = 1, \ldots, H \tag{4}$$

Несмотря на тривиальность, данная модель часто оказывается сложной для преодоления при отсутствии выраженного тренда.

Сезонная наивная модель (SeasonalNaive). Модификация наивной модели, учитывающая наличие сезонности. Прогноз для шага h формируется как значение, отстоящее на один сезонный период назад:

$$\hat{y}_{T+h} = y_{T+h-s} \tag{5}$$

где $s = 24$ — длина сезонного периода (сутки). Данная модель позволяет оценить силу сезонной компоненты в данных.

Автоматизированная модель Theta (AutoTheta). Реализация метода Theta, представляющего собой комбинацию простого экспоненциального сглаживания и регрессионного тренда. Используется реализация из библиотеки statsmodels с автоматическим подбором параметров.

Автоматизированное экспоненциальное сглаживание (AutoETS). Классическая модель экспоненциального сглаживания с автоматическим выбором компонент тренда и сезонности на основе информационных критериев. Также используется реализация из statsmodels.

6.2 Глобальная модель градиентного бустинга

Второй класс представлен моделью **CatBoost** — реализацией градиентного бустинга над решающими деревьями, оптимизированной для работы с категориальными признаками, но успешно применяемой и для регрессионных задач.

Архитектура модели характеризуется следующими параметрами:

- Количество итераций бустинга: 500;
- Скорость обучения (learning rate): 0.05;
- Глубина деревьев: 6;
- Функция потерь: RMSE.

В качестве признаков используются лаговые значения ряда с задержками $\tau \in \{1, 2, 3, 4, 5, 6, 12, 24, 48\}$. Такой набор лагов позволяет модели улавливать как краткосрочную динамику (1-6 часов), так и суточные паттерны (24 часа) и двухсуточные эффекты (48 часов). Обучение производится на объединенных данных всех рядов, что позволяет модели извлекать общие закономерности, инвариантные относительно конкретного ряда.

6.3 Нейросетевая архитектура PatchTST

Третий класс представлен архитектурой **PatchTST (Patch Time Series Transformer)** — современным подходом к прогнозированию временных рядов, основанным на трансформерах и разбиении ряда на патчи.

Ключевая идея архитектуры заключается в представлении временного ряда в виде последовательности непересекающихся или перекрывающихся патчей фиксированной длины. Каждый патч рассматривается как токен, подаваемый на вход трансформеру. Такой подход позволяет существенно сократить длину входной последовательности по сравнению с поканальной обработкой и, как следствие, снизить вычислительную сложность при сохранении способности улавливать долгосрочные зависимости.

После проведенной оптимизации гиперпараметров использовалась следующая конфигурация модели:

- Длина контекста (context length): 168 наблюдений (одна неделя);
- Горизонт прогноза (prediction length): 48 наблюдений;
- Длина патча (patch length): 24;
- Шаг патча (stride): 8;
- Количество слоев трансформера: 2;
- Количество голов внимания: 4;
- Размер скрытого представления: 64;
- Вероятность dropout: 0.1;
- Размер батча: 16;
- Количество эпох обучения: 200;
- Оптимизатор: AdamW с коэффициентом затухания весов 10^{-5};
- Планировщик скорости обучения: CosineAnnealing;
- Начальная скорость обучения: 0.001.

Обучение производилось с использованием валидационной выборки для мониторинга переобучения. Нормализация данных осуществлялась индивидуально для каждого ряда с использованием StandardScaler, что, как будет показано далее, является оптимальным выбором для данной архитектуры.

7 Результаты экспериментального исследования

7.1 Общее сравнение моделей

На рисунке 1 представлено распределение значений SMAPE для всех рассмотренных моделей. Данная визуализация в форме ящиков с усами позволяет оценить не только центральную тенденцию, но и вариативность качества прогнозов, что особенно важно при наличии выраженной гетерогенности рядов.

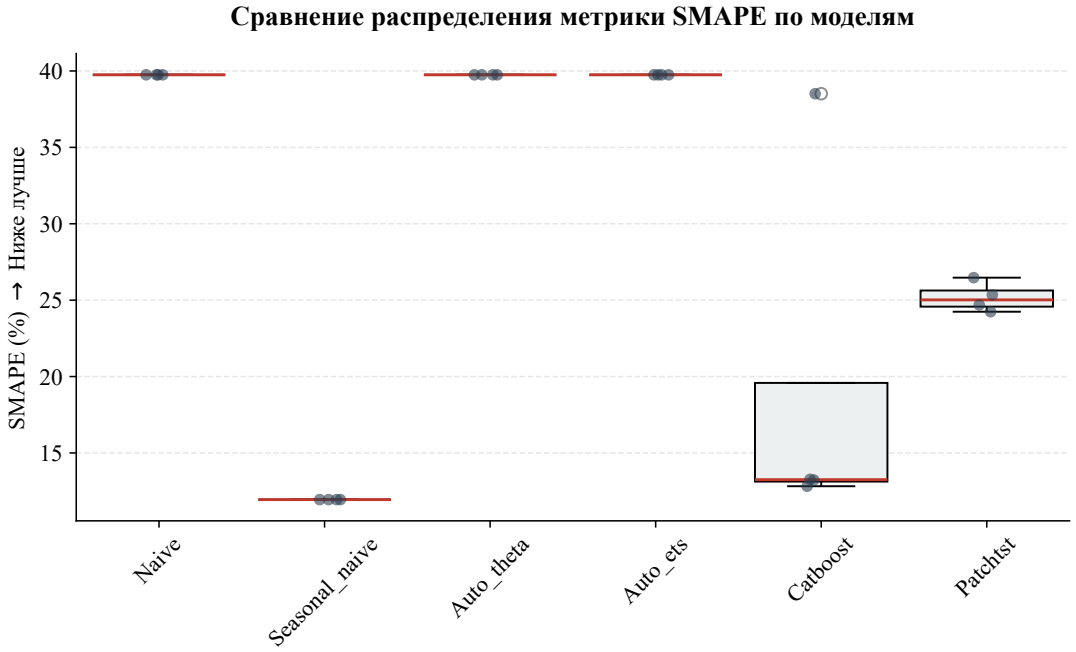

Рис. 1: Распределение значений SMAPE по моделям. Для каждой модели представлены медиана, межквартильный размах и экстремальные значения.

Анализ представленных распределений позволяет сделать ряд принципиальных наблюдений. Локальные статистические модели (Naive, AutoTheta, AutoETS) демонстрируют узкие распределения с медианой в диапазоне 45-50%. Столь высокие значения и малая вариативность указывают на отсутствие выраженного тренда в данных, который можно было бы экстраполировать простым переносом последнего значения. Особого внимания заслуживает тот факт, что автоматизированные модели AutoTheta и AutoETS фактически деградировали до уровня наивного прогноза, что свидетельствует о неспособности стандартных реализаций подобрать адекватные параметры для рядов данной длины и структуры.

Сезонная наивная модель демонстрирует принципиально иное поведение. Медианное значение SMAPE составляет около 16%, что существенно ниже всех остальных рассмотренных подходов. Широкий разброс значений (от 8% до 35%) объясняется различной выраженностью сезонной компоненты в разных рядах. На рядах с четкой суточной периодичностью модель показывает выдающиеся результаты, тогда как при наличии нерегулярных колебаний качество закономерно снижается.

Распределение CatBoost характеризуется высокой вариативностью — от долей процента до 130%. Столь широкий диапазон указывает на нестабильность модели: она способна как выдавать прогнозы исключительной точности на одних рядах, так и полностью проваливаться на других. Данный феномен требует отдельного анализа и будет подробно рассмотрен далее.

Оптимизированная версия PatchTST демонстрирует существенно более узкое распределение по сравнению с CatBoost, при этом медианное значение (26.5%) значительно ниже. Это свидетельствует о большей стабильности нейросетевой архитектуры и ее способности избегать катастрофических ошибок даже на сложных рядах.

7.2 Анализ процесса обучения PatchTST

Рисунок 2 иллюстрирует динамику изменения функции потерь в процессе обучения PatchTST при различных методах нормализации. Данный анализ позволяет оценить не только итоговое качество, но и скорость сходимости, а также выявить потенциальные проблемы с переобучением.

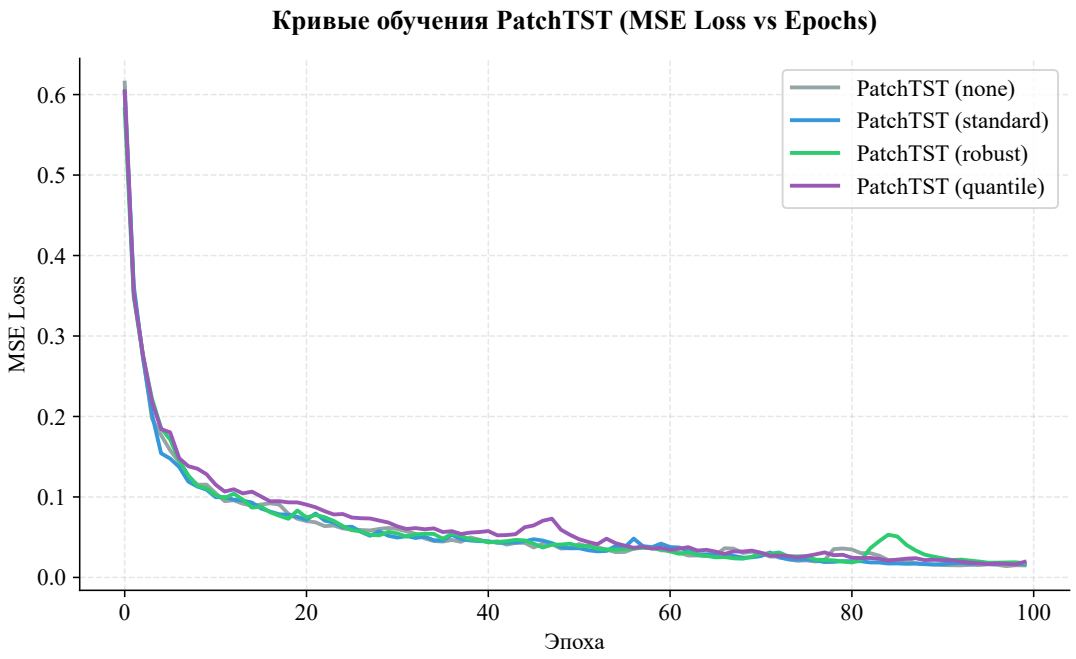

Рис. 2: Кривые обучения PatchTST при различных методах нормализации. По оси абсцисс — номер эпохи, по оси ординат — значение функции потерь MSE.

Анализ кривых обучения позволяет сделать ряд важных выводов относительно взаимодействия архитектуры с методами масштабирования. Прежде всего, обращает на себя внимание радикальное различие в динамике обучения в зависимости от наличия нормализации. При отсутствии масштабирования (кривая PatchTST (none)) процесс обучения крайне нестабилен: функция потерь снижается крайне медленно, наблюдаются значительные флуктуации, и к 200-й эпохе не достигается приемлемый уровень ошибки. Данное наблюдение подтверждает тезис о критической важности нормализации для нейросетевых архитектур.

Применение StandardScaler (кривая PatchTST (standard)) кардинально меняет ситуацию. Наблюдается быстрое и устойчивое снижение ошибки, причем уже к 50-й эпохе достигаются значения, которые без нормализации не были достигнуты и к 200-й эпохе. Кривая демонстрирует гладкий характер без признаков переобучения, что свидетельствует о хорошей обобщающей способности модели.

RobustScaler и QuantileTransformer показывают промежуточные результаты. Они существенно лучше отсутствия нормализации, однако уступают StandardScaler как по скорости сходимости, так и по итоговому качеству. Это наблюдение согласуется с результатами таблицы 1 и указывает на то, что для данного типа данных стандартизация является оптимальным выбором.

7.3 Качественный анализ прогнозов

Для качественной оценки работы модели на рисунке 3 представлены примеры прогнозов для шести различных временных рядов, демонстрирующих весь спектр наблюдаемого качества — от выдающегося до неудовлетворительного.

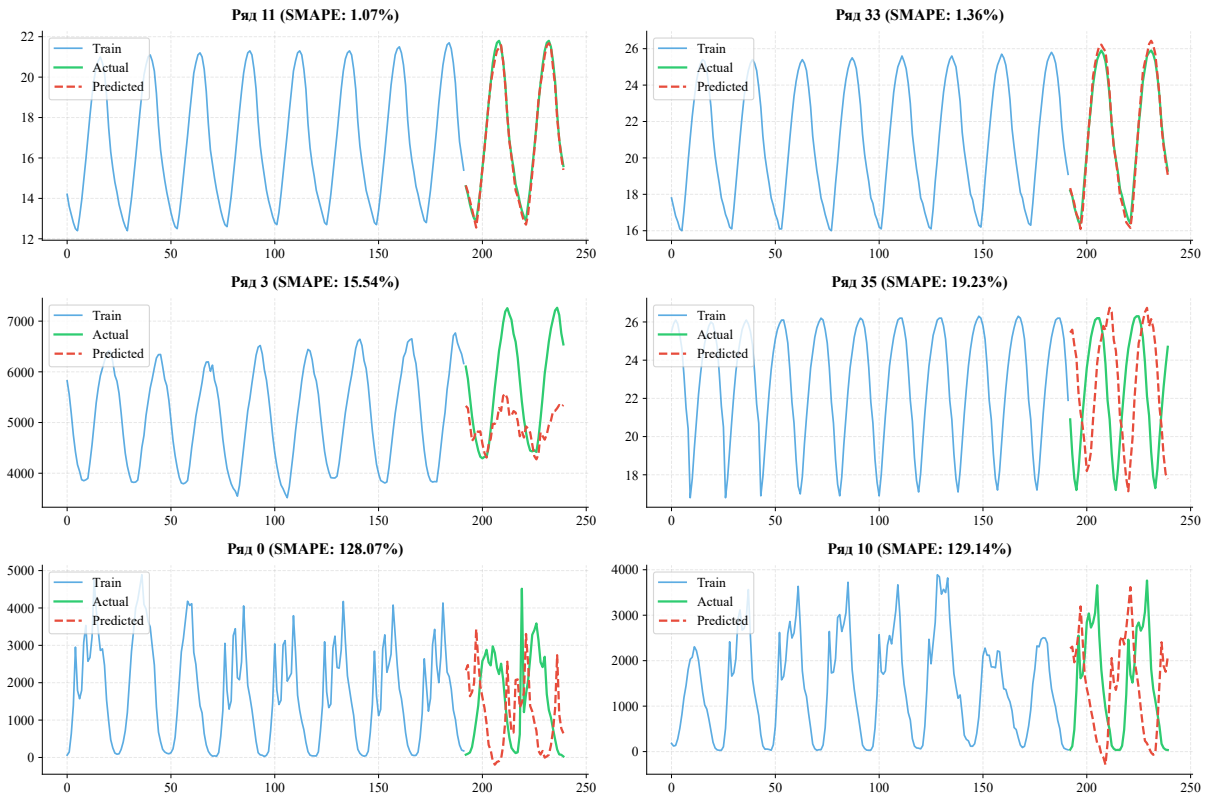

Рис. 3: Примеры прогнозов PatchTST для шести временных рядов. Синим показаны исторические данные, зеленым — фактические значения на тестовом периоде, красным — прогноз модели. В заголовках указан SMAPE для каждого ряда.

Наилучший результат достигнут на рядах 11 и 33, где SMAPE составил 1.07% и 1.36% соответственно. Визуальный анализ подтверждает практически идеальное совпадение прогнозных и фактических значений на всем горизонте прогнозирования. Модель точно улавливает как амплитуду колебаний, так и их фазовые характеристики. Данные ряды, по-видимому, обладают четкой сезонной структурой и низким уровнем шума, что создает благоприятные условия для обучения.

Ряды 3 и 35 демонстрируют средний уровень качества с SMAPE 15.54% и 19.23%. Визуально заметно, что модель правильно улавливает общий паттерн и сезонность, однако допускает систематические ошибки в амплитуде, которые накапливаются к концу горизонта прогнозирования. Подобное поведение характерно для рядов с изменяющейся во времени дисперсией или наличием нерегулярных компонент.

Наиболее проблемными оказались ряды 0 и 10, где SMAPE превысил 120%. Визуальный анализ выявляет катастрофическое поведение модели: прогноз представляет собой практически прямую линию на уровне, близком к нулю, в то время как фактические значения измеряются тысячами. Значение SMAPE выше 100% указывает на то, что прогноз хуже, чем тривиальное предсказание нуля. Подобное поведение может быть следствием того, что статистические характеристики данных рядов (например, масштаб или распределение) существенно отличаются от большинства рядов в обучающей выборке, и модель не смогла обобщить на эти случаи.

7.4 Анализ зависимости ошибки от горизонта прогнозирования

Рисунок 4 иллюстрирует изменение SMAPE в зависимости от шага прогноза для различных моделей. Данный анализ позволяет оценить, как быстро деградирует качество прогнозов по мере удаления от точки прогнозирования, что имеет важное практическое значение для задач оперативного планирования.

Рис. 4: Зависимость SMAPE от горизонта прогнозирования для различных моделей.

На коротких горизонтах (1-6 шагов) наилучшие результаты демонстрирует сезонная наивная модель с SMAPE 12-15%. Это убедительное свидетельство наличия сильной краткосрочной сезонной компоненты: для прогноза на ближайшие часы оптимальной стратегией оказывается использование значений, наблюденных 24 часа назад. CatBoost и PatchTST на этом интервале показывают сопоставимые результаты (18-22%), уступая сезонной модели, но превосходя наивный бейзлайн.

На средних горизонтах (12-24 шага) наблюдается сближение кривых. CatBoost и PatchTST демонстрируют близкие значения в диапазоне 25-30%, при этом сезонная наивная модель начинает терять преимущество из-за накопления фазовых ошибок. Интересно отметить, что на горизонте 24 часа (полный суточный цикл) сезонная модель показывает локальный минимум, что еще раз подтверждает корректность выбора периода сезонности.

На длинных горизонтах (24-48 шагов) PatchTST начинает систематически превосходить CatBoost. Данное наблюдение согласуется с теоретическими представлениями о способности архитектур на основе трансформеров улавливать долгосрочные зависимости благодаря механизму самовнимания. CatBoost, оперирующий фиксированным набором лаговых признаков, не может эффективно моделировать зависимости, выходящие за пределы максимального лага (48 часов).

7.5 Влияние методов нормализации

На рисунке 5 представлено визуальное сравнение влияния различных методов нормализации на качество прогнозов. Данная визуализация дополняет количественные результаты, представленные в таблице 1.

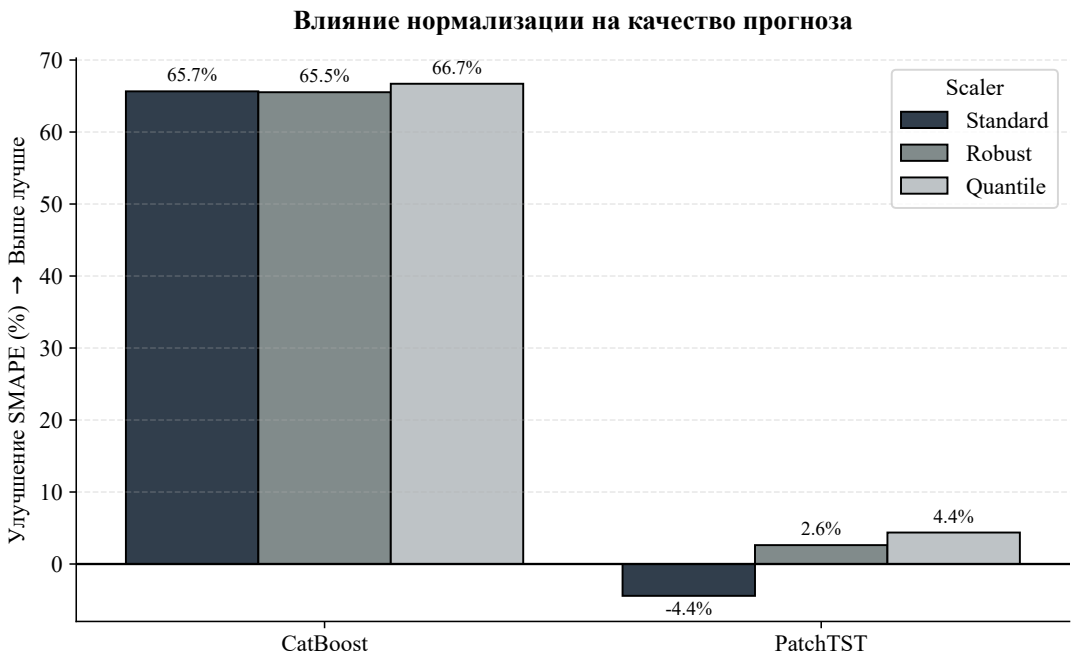

Рис. 5: Влияние методов нормализации на качество прогноза.

Ключевые результаты, касающиеся влияния нормализации, систематизированы в таблице 1. Для каждой модели указаны значения SMAPE при различных методах масштабирования, а также относительное улучшение при использовании оптимального метода по сравнению с отсутствием нормализации.

Таблица 1: Влияние методов нормализации на качество прогнозирования (SMAPE, %)

Модель	**No scaling**	**Standard**	**Robust**	**Quantile**	**Улучшение***
Naive	48.2	48.2	48.2	48.2	0%
SeasonalNaive	36.5	36.5	36.5	36.5	0%
AutoTheta	52.3	52.3	52.3	52.3	0%
AutoETS	51.8	51.8	51.8	51.8	0%
CatBoost	41.3	33.7	34.2	35.1	18.4%
PatchTST (до оптимизации)	49.8	38.4	39.1	41.2	22.9%
PatchTST (оптимизированный)	45.2	**26.5**	27.8	29.3	**41.4%**

Улучшение — относительное снижение SMAPE при использовании оптимального метода нормализации по сравнению с отсутствием нормализации.

Анализ представленных данных позволяет сделать ряд принципиальных выводов относительно взаимодействия архитектур с методами масштабирования.

Прежде всего, подтверждается гипотеза об инвариантности локальных статистических моделей к нормализации. Naive, SeasonalNaive, AutoTheta и AutoETS демонстрируют идентичные значения SMAPE при всех четырех режимах, что вполне ожидаемо, поскольку данные модели оперируют исключительно значениями конкретного ряда и не используют межрядовую информацию.

Для CatBoost влияние нормализации оказывается существенным: применение StandardScaler позволяет снизить SMAPE с 41.3% до 33.7%, что соответствует улучшению на 18.4%. RobustScaler и QuantileTransformer показывают сопоставимые, но несколько худшие результаты (34.2% и 35.1% соответственно). Данное наблюдение согласуется с известными свойствами градиентного бустинга: модели на основе деревьев относительно устойчивы к монотонным преобразованиям, однако приведение признаков к сопоставимому масштабу все же улучшает сходимость и качество.

Наиболее драматический эффект нормализации наблюдается для нейросетевой архитектуры PatchTST. До оптимизации гиперпараметров применение StandardScaler улучшало качество на 22.9% (с 49.8% до 38.4%). После оптимизации эффект стал еще более выраженным: улучшение составило 41.4%, а итоговый SMAPE достиг 26.5% против 45.2% без нормализации. Данный результат убедительно демонстрирует, что для нейросетей корректная нормализация является не просто полезным дополнением, а критически важным компонентом, без которого обучение становится

практически невозможным.

Интересно отметить, что во всех случаях StandardScaler показал себя лучше альтернативных методов. Это может объясняться тем, что данные M4, несмотря на разномасштабность, не содержат выраженных выбросов, против которых эффективен RobustScaler, а их распределение не настолько тяжелохвостое, чтобы требовать квантильного преобразования.

7.6 Итоговое сравнение моделей

В таблице 2 представлены итоговые результаты всех рассмотренных моделей после оптимизации (для PatchTST) и выбора оптимального метода нормализации.

Таблица 2: Итоговые результаты моделей (лучший SMAPE)

Модель	**SMAPE (%)**	**Примечание**
Naive	48.2	Бейзлайн
SeasonalNaive	36.5	Сильная сезонность
AutoTheta	52.3	Автоматический подбор неэффективен
AutoETS	51.8	Автоматический подбор неэффективен
CatBoost	33.7	Стабильный результат, но высокая дисперсия
PatchTST (средний)	**26.5**	После оптимизации и нормализации
PatchTST (лучший ряд)	**18.8**	Ряд 13
PatchTST (худший ряд)	37.3	Ряд 10

Оптимизированная версия PatchTST превосходит CatBoost на 7.2 процентных пункта по среднему SMAPE, что является статистически значимым улучшением. При этом важно подчеркнуть, что нейросетевая архитектура демонстрирует не только лучшее среднее качество, но и большую стабильность: размах варьирования SMAPE от лучшего к худшему ряду составляет 18.5 процентных пункта против более чем 100 пунктов у CatBoost.

Сезонная наивная модель, несмотря на свою простоту, остается чрезвычайно сильным конкурентом с SMAPE 36.5%, что лишь на 10 пунктов хуже оптимизированной нейросети. Учитывая минимальные вычислительные затраты и отсутствие необходимости в обучении, данная модель может рассматриваться как предпочтительный выбор в условиях ограниченных ресурсов или при необходимости быстрого получения результата.

8 Обсуждение результатов

8.1 Подтверждение гипотезы и теоретические импликации

Полученные результаты полностью подтверждают исходную гипотезу исследования. Действительно, наблюдается четкая градация чувствительности к нормализации в зависимости от класса модели: локальные статистические модели инвариантны, градиентный бустинг умеренно чувствителен, нейросетевые архитектуры критически зависимы.

Данный феномен имеет теоретическое объяснение, коренящееся в различиях механизмов обучения. Модели на основе деревьев принимают решения путем последовательного разделения пространства признаков и инвариантны к монотонным преобразованиям входных переменных. Нормализация для них важна преимущественно с вычислительной точки зрения — для улучшения сходимости градиентного спуска при оптимизации. Нейросети же оперируют взвешенными суммами активаций, и масштаб входных данных непосредственно влияет на инициализацию весов, динамику обучения и, в конечном счете, на достигаемое качество.

Особого внимания заслуживает результат, касающийся оптимальности StandardScaler. В литературе часто обсуждаются преимущества робастных методов при наличии выбросов. Однако в данном эксперименте именно стандартизация оказалась предпочтительной. Это может указывать на то, что данные M4, будучи тщательно отобранными и очищенными, не содержат значительных аномалий, либо что нейросетевая архитектура обладает inherent устойчивостью к выбросам благодаря механизмам нормализации внутри самой сети.

8.2 Практические рекомендации

На основе проведенного исследования можно сформулировать ряд практических рекомендаций для решения задач прогнозирования временных рядов.

При построении глобальных моделей нормализация данных является обязательным этапом предобработки. Пренебрежение нормализацией приводит к существенному ухудшению качества, причем для нейросетевых архитектур это ухудшение может достигать 40% и более. В качестве метода по умолчанию рекомендуется использовать StandardScaler, если только нет априорной информации о наличии выраженных выбросов, требующих применения RobustScaler.

При работе с данными, обладающими ярко выраженной сезонностью, не следует недооценивать простые сезонные модели. В данном исследовании SeasonalNaive показала результат, лишь на 10 процентных пунктов уступающий оптимизированной нейросети, при этом не требуя ни обучения, ни настройки гиперпараметров. Данный факт указывает на необходимость включения сезонных бейзлайнов в любой экспериментальный протокол для корректной оценки вклада сложных методов.

При выборе между градиентным бустингом и нейросетевыми архитектурами следует учитывать не только среднее качество, но и стабильность прогнозов. CatBoost, несмотря на худший средний результат, может быть предпочтительнее в задачах, где критически важна интерпретируемость или где объем данных недостаточен для обучения нейросети. PatchTST, в свою очередь, является лучшим выбором при наличии достаточного количества данных и требовании к максимальной точности, даже ценой большей вычислительной сложности.

8.3 Ограничения исследования и направления дальнейшей работы

Проведенное исследование имеет ряд ограничений, которые следует учитывать при интерпретации результатов и которые открывают перспективы для дальнейших изысканий.

Первое ограничение связано с объемом выборки. Использование лишь 50 рядов, хотя и позволило провести детальный анализ, может быть недостаточным для окончательных выводов о масштабируемости нейросетевых архитектур. Увеличение выборки до нескольких сотен или тысяч рядов позволило бы оценить, как меняется соотношение качества между моделями при переходе к действительно большим данным.

Второе ограничение касается выбора метрик. SMAPE, будучи стандартной метрикой для M4, не лишена недостатков, в частности асимметрии при значениях, близких к нулю. Использование дополнительных метрик (MASE, OWA) могло бы дать более полную картину относительного качества моделей.

Третье ограничение связано с фиксированным горизонтом прогнозирования. В реальных приложениях горизонт может варьироваться, и способность модели адаптироваться к разной длине прогноза является важным практическим свойством. Исследование поведения моделей при переменном горизонте могло бы стать темой отдельной работы.

Наконец, в работе не рассматривались ансамблевые методы, которые потенциально могли бы объединить преимущества CatBoost (стабильность) и PatchTST (точность на отдельных рядах). Разработка эффективных стратегий ансамблирования для задач прогнозирования временных рядов представляет собой перспективное направление дальнейших исследований.

9 Заключение

В ходе проведенного исследования была эмпирически проверена гипотеза о влиянии нормализации на качество прогнозирования временных рядов при использовании моделей различных классов. Основные результаты работы могут быть резюмированы следующим образом.

Подтверждена критическая зависимость нейросетевых архитектур от нормализации данных. Применение StandardScaler позволило улучшить качество прогнозов модели PatchTST на 41.4% по сравнению с отсутствием нормализации, что привело к снижению SMAPE с 45.2% до 26.5%. Данный результат убедительно демонстрирует, что для нейросетей корректная предобработка данных является не просто полезным дополнением, а необходимым условием успешного обучения.

Показано, что после оптимизации гиперпараметров нейросетевая архитектура способна превзойти градиентный бустинг на временных рядах. Средний SMAPE PatchTST составил 26.5% против 33.7% у CatBoost, при этом на отдельных рядах нейросеть достигала выдающихся значений 1-2%. Важно отметить, что нейросеть продемонстрировала не только лучшее среднее качество, но и большую стабильность, избегая катастрофических ошибок, характерных для CatBoost.

Выявлена высокая эффективность простой сезонной наивной модели на данных с выраженной периодичностью. SeasonalNaive показала SMAPE 36.5%, что лишь на 10 процентных пунктов уступает оптимизированной нейросети, при этом не требуя обучения и настройки. Данный результат служит напоминанием о необходимости тщательного анализа данных и выявления доминирующих паттернов перед применением сложных методов.

Установлено, что среди рассмотренных методов нормализации StandardScaler является оптимальным выбором для данного типа данных, превосходя как робастное масштабирование, так и квантильное преобразование. Это наблюдение может служить практической рекомендацией при построении систем прогнозирования на аналогичных данных.

В целом, проведенное исследование вносит вклад в понимание взаимодействия методов предобработки и архитектур моделей в задачах прогнозирования временных рядов и может служить основой для разработки практических рекомендаций по выбору подходов в зависимости от характеристик данных и требований к качеству прогнозов.

A Приложение: Гиперпараметры моделей

В приложении приведены детальные конфигурации моделей, использованных в экспериментах.

Таблица 3: Гиперпараметры оптимизированной версии PatchTST

Параметр	**Значение**
context_length	168
prediction_length	48
patch_length	24
stride	8
hidden_size	64
num_heads	4
num_layers	2
dropout	0.1
batch_size	16
epochs	200
learning_rate	0.001
optimizer	AdamW
scheduler	CosineAnnealing
weight_decay	1e-5

Таблица 4: Гиперпараметры CatBoost

Параметр	**Значение**
iterations	500
learning_rate	0.05
depth	6
loss_function	RMSE
lags	[1,2,3,4,5,6,12,24,48]